



Fundação CECIERJ - Vice Presidência de Educação Superior a Distância

## **Curso de Tecnologia em Sistemas de Computação**

### **Disciplina: Computação Gráfica**

**AD2 - 2º semestre de 2019.**

- 1) A NVIDIA lançou uma GPU, com uma arquitetura denominada Turing. Esta GPU processa o Ray-tracing no hardware, realizando diversas etapas importantes nela. Uma delas é o cálculo de denoising. O que é o denoising? (1.0 ponto).

*Denoising consiste em completar pixels que não puderam ser tratados pelo path-tracing, usando técnicas de Inteligência Artificial. A NVIDIA possui em seu hardware componentes que permitem o cálculo rápido desta etapa.*

- 2) CUDA é uma biblioteca para programar GPUs, com propósito geral.

Explique conceitos básicos e exemplos do que pode ser feito.

*A computação de alto desempenho ganhou uma nova ferramenta com o surgimento do CUDA (Compute Unified Device Architecture) em junho de 2007.*

*A ferramenta CUDA permitiu a programação das placas gráficas (GPUs - Graphic Processors Unit), para computação de propósito geral, de forma mais transparente para o desenvolvedor. Contudo, estes dispositivos já estavam sendo utilizados para cálculos de propósito gerais a alguns anos. Naquela época, os dados eram ser modelados em vértices e pixels.*

*A utilização deste hardware se deu por ser um dispositivo dedicado, com alto poder de processamento massivamente paralelo e de baixo custo, quando comparado com as CPUs. A arquitetura das GPUs permite a construção de chips de baixo custo com e centenas de cores, atualmente há placas compostas por milhares de cores.*

*No início da utilização das placas gráficas, os gráficos eram geridos através de controladores VGA, que apenas manipulavam memória de vídeo. Em 1997, alguns fabricantes começaram a incluir funcionalidades de hardware capazes de implementar parte do chamado pipeline gráfico em tempo real, tais como rasterização, mapeamento de textura e, em placas maior poder de processamento, cálculos de sombreadimento. No final do ano de 2000, estes dispositivos eram capazes de processar todo o pipeline gráfico, deixando as CPUs livres da maioria das tarefas de rasterização e passaram a equipar todos os computadores pessoais e consoles, combinando o processamento da CPU com a GPU e formando sistemas heterogêneo.*

*Basicamente, a arquitetura da GPU é classificada como um modelo do tipo Single Instruction, Multiple Threads (SIMT). Isto quer dizer que diversas threads executam a mesma instrução a cada ciclo de clock. Além disso, no modelo de programação do CUDA, as thread são organizadas em blocos,*

*formando uma organização lógica das instâncias do kernel. Na parte de hardware, as GPUs são organizadas em multiprocessadores (SMPs - symmetric multiprocessors) idênticos, cada um dos SMPs é composto por centenas de cores, memórias e registradores.*

*A execução das threads envolve o escalonamento das mesmas em dois níveis: no primeiro nível, os blocos de threads são escalonados nos SMPs; e, no segundo nível, as threads do bloco são escalonadas nos cores. O número de SMPs pode variar de acordo com o modelo de geração e GPU. Muitas mudanças no projeto de um SMP foram feitas desde a primeira versão da GPU a fim de melhorar a performance e o consumo de energia destes processadores. Há um limite de threads e blocos que podem ser alocados em uma GPU. Atualmente o limite de threads por blocos é de 1.024 e a quantidade de blocos é de 2.147.483.647, assim é possível lançar 2.199.023.254.528 threads em uma única GPU. Por fim, conceitualmente os blocos são agrupados formando uma grid.*

*A GPU tem diferentes memórias, cada um com capacidade e velocidade de acesso diferente e são organizadas da seguinte forma:*

- A memória global, que é a memória principal e pode ir até 12GB em arquitetura Maxwell. Todos os núcleos / threads podem acessar diretamente essa memória, mas há uma latência alta e uma baixa produção. Os dados a partir desta memória tem o tempo de vida da grelha.*
- A memória compartilhada, que é uma memória de baixa latência, tem uma alta taxa de transferência e é dedicado a cada SM. Apenas segmentos pertencentes ao mesmo bloco pode aceder a esta memória e o tempo de vida é o mesmo do bloco. Quando um bloco termina, a memória compartilhada é apagada, mesmo para um bloco subsequente que irá utilizar o mesmo SM.*
- A memória local, assim chamado porque o seu âmbito é local para o segmento, não por causa de sua localização física. Memória local é off-chip tornando o acesso a ele tão caro como o acesso à memória global.. Esta memória é acessível somente para um segmento específico e dados persiste apenas durante a execução de discussão.*
- A textura de memória, que corresponde a uma memória só de leitura e em cache, resultando em uma leitura a partir do cache. Ele é otimizado para localidade espacial 2D, permitindo que segmentos que estão perto de usar a mesma operação de leitura para os dados correspondentes, no caso de haver coalescência. Essa memória também é capaz de interpolação de dados, operação típica na resolução de textura anti-aliasing.*
- A memória constante, que também é armazenado em cache e custam uma operação de leitura a partir do cache, caso seja evitado um cache miss. É uma pequena memória, com 64 KB.*

*A CPU é capaz de ler e escrever na memória global da GPU, este processo ocorre através do barramento de dados que atualmente é o PCI-EXPRESS. Toda a comunicação entre o host e o device é por via deste canal.*

*O escalonamento dentro de cada SMP é feito em grupos de 32 threads. Assim, 32 threads consecutivas executam a mesma instrução. Ao fim da execução da última instrução, outras 32 threads consecutivas são escalonadas. Este procedimento de escalonamento é conhecido como warp. Neste sentido, recomenda-se instanciar a quantidade de threads em um bloco em múltiplo de 32. Alinhando os dados da memória com as threads de um warp, é garantido o*

*melhor padrão de acesso à memória, ou seja, o acesso é coalescente. No procedimento de escalonamento, é criado dois índices: um índice é referente ao bloco que uma determinada thread pertence e o outro é o índice da thread dentro do bloco que ela pertence. Como 32 threads de um mesmo warp executam as mesmas instruções, uma importante otimização é garantir que estas threads tenham o mesmo caminho de dados. Neste sentido, se há divergência no fluxo de execução do código em uma ou mais threads de um mesmo warp, algumas threads podem ficar ociosas, serializando a execução. Em versões mais antigas do CUDA, só era permitido criar grids com o mesmo kernel, ou seja, não existia a possibilidade de executar kernels concorrentes. Com o lançamento da arquitetura Fermi, passou a ser possível executar mais de um kernel ao mesmo tempo. Contudo, apenas a arquitetura Kepler realmente implementa a execução de kernels concorrentes. Isto porque o distribuidor de tarefas da Kepler colocou o código dentro de um pipeline único. Kernels concorrentes são escalonados internamente pela GPU e um SMP pode executar apenas o mesmo kernel. Na prática, isto significa que cada bloco pode ter apenas threads instanciadas de um mesmo kernel e o kernel concorrente é escalonado em outro SMP. Com o lançamento da arquitetura Kepler, uma nova tecnologia chamada Hyper-Q foi introduzida na GPU que permite diferentes programas ou threads de CPU dispararem diferentes kernels em uma mesma GPU. Até então, quando um kernel era disparado, a GPU ficava ocupada executando este kernel e não recebia outros kernels de outros programas ou threads de CPU, sendo necessário um sincronismo por barreira para que uma grid fosse finalizada antes de inicializar outra. Um outro recurso introduzido na arquitetura Kepler é o chamado paralelismo dinâmico, que permite que sejam lançados kernels dentro de outros kernels. Até o surgimento deste recurso, apenas a CPU era capaz de lançar kernels. Este novo recurso passou a permitir que os SMPs possam chamar kernels diretamente do dispositivo. A seção de programação irá mostrar estes recursos.*

3) O que é o DXR (DirectX Ray-tracing)? (1.0 ponto).

*DXR é uma API gráfica para lidar com o ray-tracing em GPU. Podemos dizer que o DXR equivale ao OpenGL porém para o Ray-tracing. A API já implementa uma série de funcionalidades típicas do RT usando o hardware, quando possível: interseção de raios, busca na BVH, computação da iluminação, dentre outras.*

4) O que é motion sickness em Realidade Virtual? (1.0 pontos)

*Motion Sickness é o efeito de mal estar que ambientes de realidade virtual podem causar aos usuários. Pode ser causado por muitos fatores, mas especialmente por problemas de latência e falta de correspondência entre as imagens vistas pelo usuário e os movimentos do mesmo. Uma forma simples de minimizar consiste em criar aplicações que tenham movimentos de câmera suaves.*

- 5) Um jogador de vídeo-game reclama que uma textura de um quadro de uma sala fica piscando quando ele se afasta demais do objeto. Explique tecnicamente para ele o que é que está acontecendo. (1.0 ponto).

*O problema que acontece é conhecido como alias. Acorre porque a textura é armazenada contém um número finito de valores discretos de alguns imagem original, ou seja, a uma perda da informação. Ao ser aplicada sobre uma primitiva do OpenGL, por exemplo. Ao realizar a varredura de conversão da textura para o polígono, as suas coordenadas de textura são mapeados em coordenadas (u, v) e a textura é re-amostrados usando essas coordenadas. Assim, no caso em que o polígono é encolhido devido à perspectiva, que irá abranger apenas alguns pixels. Isso resultará em apenas um dos pontos de amostragem poucos espalhados por toda a imagem de textura e, portanto, causando este efeito indesejado.*

- 6) Quando um artista de um game lhe diz que é necessário melhorar a estratégia de Culling, pois o frame-rate está baixo, o que ele quer dizer exatamente?

*Quando o artista diz isto é porque provavelmente ele detectou que o jogo está com uma sobrecarga e um gargalo no número de polígonos sendo renderizados. Ao dizer que precisa de uma estratégia de culling ele quer dizer que é necessário alguma estratégia para eliminar polígonos não visíveis.*

- 7) Diferencie o conceito de Iluminação global e iluminação local. (1 ponto)

*Iluminação global é aquela que leva em consideração todos os raios de luz do cenário, incluindo aqueles derivados de múltiplas reflexões e difrações. Iluminação local é aquela que apenas considera os raios de luz derivados diretamente da fonte de luz.*

- 8) O que é o Path-tracing? (1.0 ponto)

*O path-tracing é uma extensão do ray-tracing e consiste em lançar mais do que um raio recursivo, de forma a modelar os raios de luz que compõem a iluminação difusa, seguindo o modelo de Lambert. Se por um lado o path-tracing modela de forma muito mais realista a iluminação de uma cena, por outro encarece enormemente o volume de cálculos.*

- 9) O que são as BVHs?(1.0 ponto)

*A BVH (Bounding Volume Hierarchy) é uma estrutura de dados espacial, que subdivide o espaço, englobando objetos por caixas, simplificando etapas de cálculo de interseção, já que ao invés de calcular a mesma com todos os polígonos da cena, apenas se calcula com as caixas, que contém muito menos polígonos. Estas estruturas são importantes para realizar cullings e processos de aceleração em buscas espaciais.*

10) Diferencie Clipping de Culling (1.0 ponto)

*Clipping consiste em recortar os polígonos que ficaram fora da área de projeção da tela. Em casos onde polígonos ficam parte dentro e parte fora, é feito um recorte dos mesmos, deixando apenas a parte que fica dentro da área de projeção. O culling por outro lado consiste em estratégias para tentar descobrir e descartar polígonos que, quando projetados e transformados, ficarão invisíveis. Esta invisibilidade pode ser por oclusão ou por estar fora do campo de visão da câmera.*